

# Mestrado em Engenharia e Gestão Industrial

## Inteligência Artificial aplicada na Indústria

### Métricas

**Daniel Nogueira**



[dnogueira@ipca.pt](mailto:dnogueira@ipca.pt)






<https://www.linkedin.com/in/danielfnogueira/>



# Metrics

## Machine Learning Models




Reference: Input (Dataset)

# Metrics

Machine Learning Models

Reference: Output

Classification Models




# Metrics


Machine Learning Models

Classification Models


Decision Tree




Naive Bayes



Random Forest



Support Vector Machine




Machine Learning Models

Classification Models

Regression Models

# Metrics

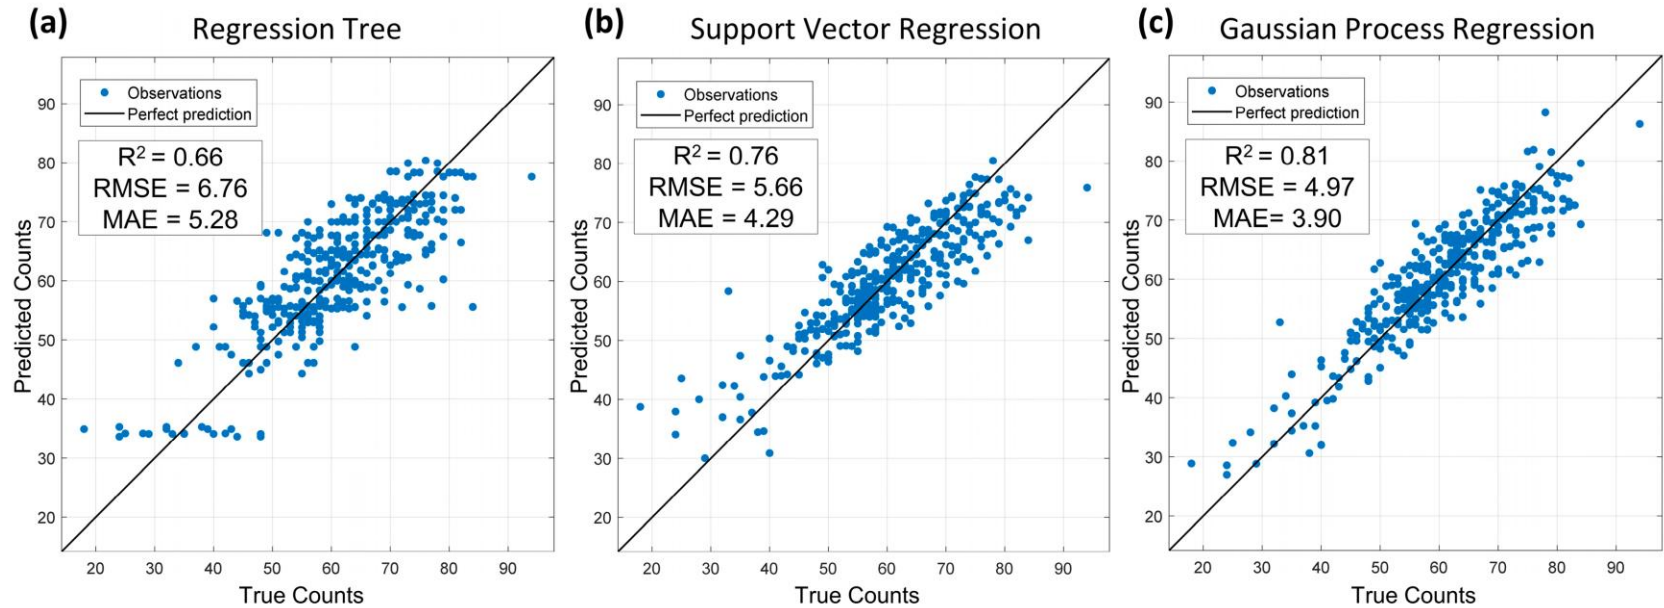


# Metrics

Machine Learning Models

Classification Models

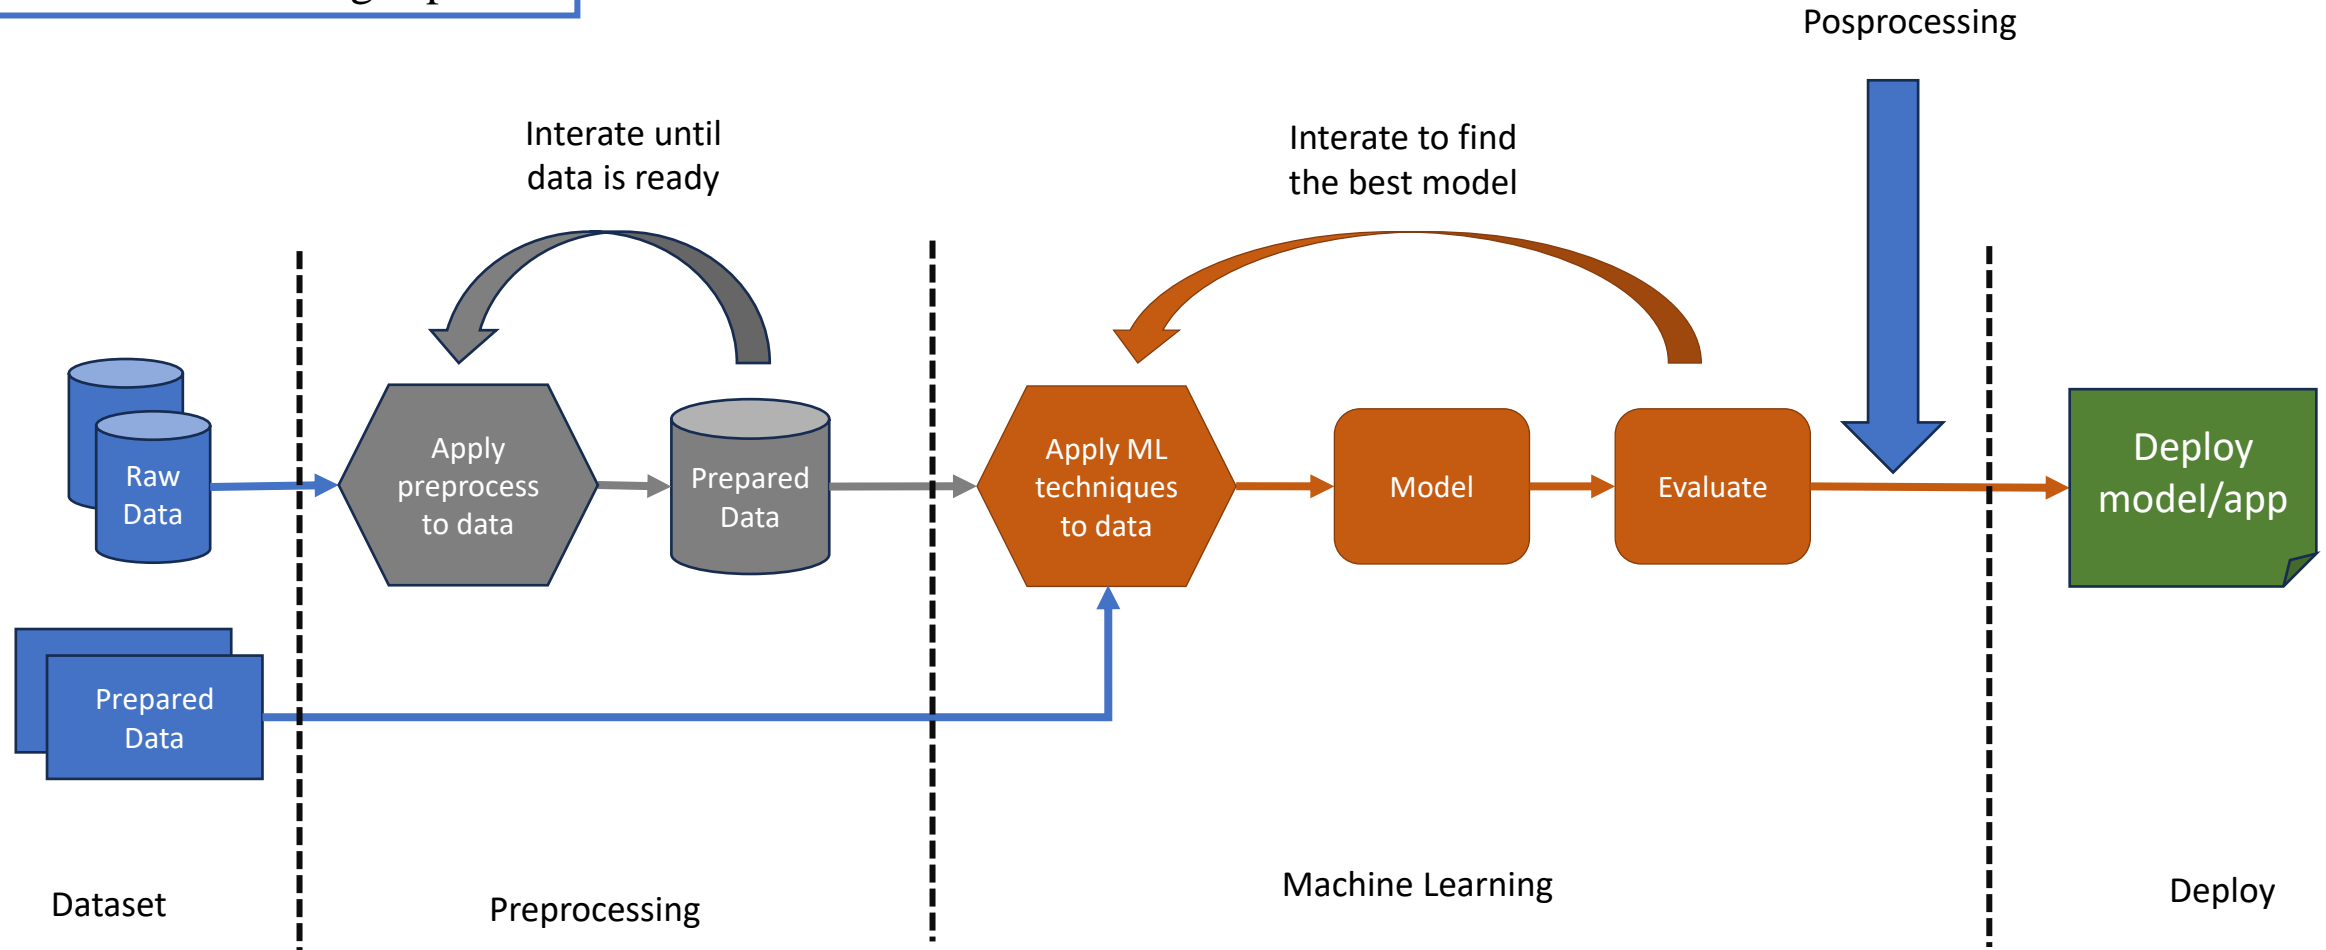
Regression Models








# Metrics

## Machine Learning Pipeline



# Metrics

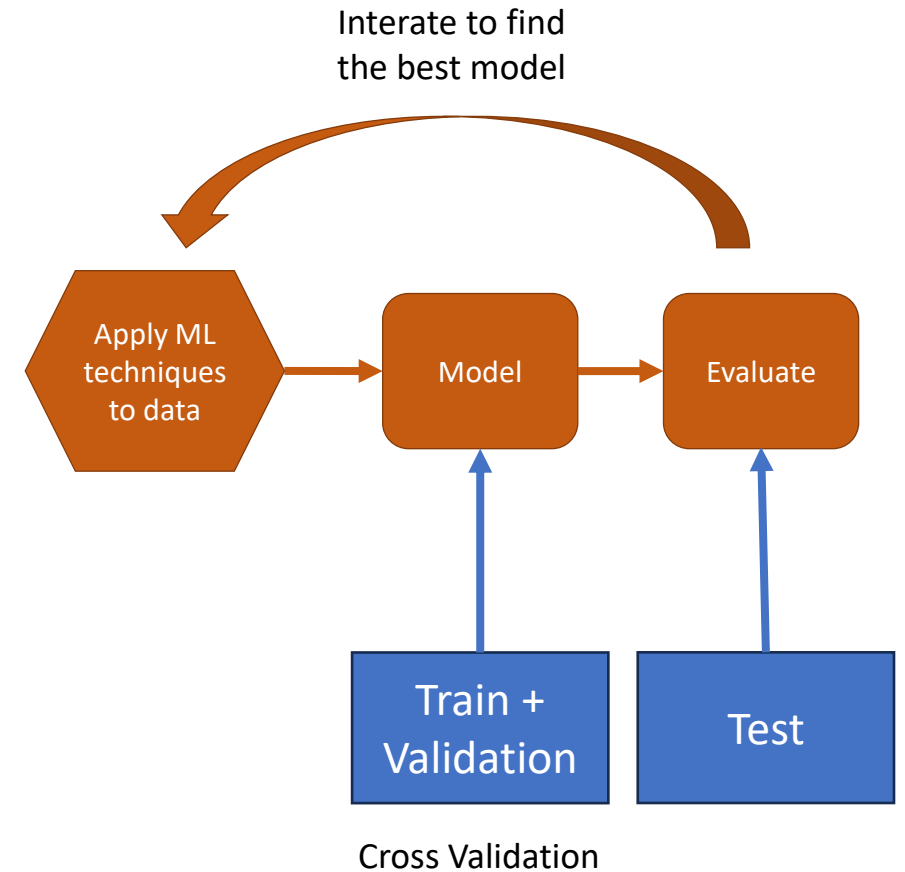


Dataset





# Metrics

Dataset



# Metrics

## Accuracy


Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

## Precision

Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo



High Accuracy  
High Precision????

# Metrics

## Accuracy


Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

## Precision

Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo



Low Accuracy  
Low Precision

# Metrics

## Accuracy


Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

## Precision

Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo



Low Accuracy  
Low Precision

# Metrics

## Accuracy

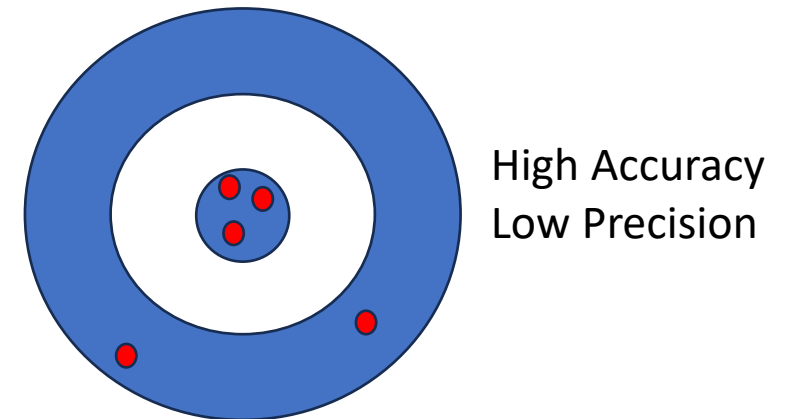
Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

## Precision

Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo



# Metrics

## Accuracy


Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

## Precision

Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo



# Metrics

## Accuracy


Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

## Precision

Precision mede a proximidade entre seus resultados.


Precision é usada ao longo do tempo









# Metrics

TP – True Positive  
 FP – False Positive  
 TN – True Negative  
 FN – False Negative



# Metrics

		Predicted	
Actual			
			

		Predicted		
		Positive	Negative	
Actual	Positive	True positive(TP)	False Negative(FN)	Sensitivity or Recall or True Positive Rate= $TP/(TP+FN)$
	Negative	False Positive (FP)	True Negative(TN)	Specificity or True Negative Rate= $TN/(TN+FP)$
		Precision or Positive Predictive Value= $TP/(TP+FP)$	Negative Predictive Value= $FN/(FN+TN)$	Accuracy= $TP+TN/TP+TN+FP+FN$

# Metrics

## ➤ Accuracy (Acurácia):

- **Definição:** A acurácia mede a proporção de previsões corretas feitas por um modelo em relação ao número total de previsões.
- **Foco:** É uma métrica geral que avalia o desempenho global do modelo, levando em conta verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

$$Accuracy = \frac{TP}{TP + FP + FN + TN}$$

# Metrics

## ➤ Accuracy (Acurácia):

- **Definição:** A acurácia mede a proporção de previsões corretas feitas por um modelo em relação ao número total de previsões.
- **Foco:** É uma métrica geral que avalia o desempenho global do modelo, levando em conta verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

## ➤ Precision (Precisão):


- **Definição:** A precisão mede a proporção de previsões positivas corretas em relação ao número total de previsões positivas feitas pelo modelo.
- **Foco:** É importante quando você deseja minimizar falsos positivos, ou seja, quando a identificação incorreta de casos positivos é crítica.

$$Precision = \frac{TP}{TP + FP}$$


# Metrics

$$Accuracy = \frac{TP}{TP + FP + FN + TN}$$


$$Precision = \frac{TP}{TP + FP}$$




High Accuracy  
Low Precision



High Accuracy  
High Precision



Low Accuracy  
Low Precision



Low Accuracy  
High Precision

# Metrics

## ➤ Accuracy (Acurácia):

- **Definição:** A acurácia mede a proporção de previsões corretas feitas por um modelo em relação ao número total de previsões.
- **Foco:** É uma métrica geral que avalia o desempenho global do modelo, levando em conta verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

## ➤ Precision (Precisão):

- **Definição:** A precisão mede a proporção de previsões positivas corretas em relação ao número total de previsões positivas feitas pelo modelo.
- **Foco:** É importante quando você deseja minimizar falsos positivos, ou seja, quando a identificação incorreta de casos positivos é crítica.

## ➤ Recall (Revocação):





- **Definição:** Recall, também conhecido como Sensibilidade ou Taxa de Verdadeiros Positivos, mede a capacidade de um modelo de identificar todos os exemplos **relevantes** em um conjunto de dados.
- **Foco:** É particularmente importante quando você deseja minimizar falsos negativos, ou seja, quando a não detecção de casos positivos é crítica.

# Metrics

$$Accuracy = \frac{TP}{TP + FP + FN + TN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$





# Metrics

$$Accuracy = \frac{TP}{TP + FP + FN + TN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

## ➤ F1 Score:


- **Definição:** é uma métrica de avaliação que combina as métricas de precision e recall em um único número, fornecendo uma medida geral do desempenho de um modelo.
- **Foco:** é particularmente útil para encontrar um equilíbrio entre a precision e a capacidade de recuperar todos os casos positivos (recall). O F1 Score é calculado pela média harmônica da precision e recall.
- ❖ O F1 Score varia de 0 a 1, onde 1 indica um modelo perfeito que atinge tanto alta precisão quanto alta revocação.
- ❖ É especialmente útil quando as consequências de falsos positivos e falsos negativos são críticas e você deseja encontrar um equilíbrio entre esses dois tipos de erros.
- ❖ É amplamente utilizado em problemas de classificação binária, como detecção de spam, diagnóstico médico, ou classificação de sentimentos.

$$F1\ score = \frac{2 * Precision * Recall}{Precision + Recall} = \frac{TP}{TP + \frac{FP}{2} + \frac{FN}{2}}$$


# Metrics

## Confusion Matrix

- 150 samples (80% train + 20% test)
  - 3 classes (setosa, versicolor, virginica)
  - 30 test samples (test dataset):
    - ✓ Setosa – 11 samples (11 predicted)
    - ✓ Versicolor – 11 samples (10 predicted)
    - ✓ Virginica – 8 samples (9 predicted)
- 1 sample predicted Virginica => Versicolor (real)




# Metrics



$$Accuracy = \frac{11 + 10 + 8}{11 + 11 + 8} = \frac{29}{30} = 0.9667$$

# Metrics



Setosa: TP = 11 | FP = 0 | FN = 0  
 Versicolor: TP = 10 | FP = 0 | FN = 1  
 Virginica: TP = 8 | FP = 1 | FN = 0

$$Precision_{setosa} = \frac{11}{11 + 0} = \frac{11}{11} = 1$$

$$Recall_{setosa} = \frac{11}{11 + 0} = \frac{11}{11} = 1$$


$$Precision_{versicolor} = \frac{10}{10 + 0} = \frac{10}{10} = 1$$

$$Recall_{versicolor} = \frac{10}{10 + 1} = \frac{10}{11} = 0.9091$$

$$Precision_{virginica} = \frac{8}{8 + 1} = \frac{8}{9} = 0.8889$$

$$Recall_{virginica} = \frac{8}{8 + 0} = \frac{8}{8} = 1$$

# Metrics



Setosa: TP = 11 | FP = 0 | FN = 0

Versicolor: TP = 10 | FP = 0 | FN = 1

Virginica: TP = 8 | FP = 1 | FN = 0

$$F1_{setosa} = \frac{2 * 1 * 1}{1 + 1} = \frac{2}{2} = 1$$

$$W_{setosa} = \frac{11}{30} = 0.3666$$


$$F1_{versicolor} = \frac{2 * 1 * 0.9091}{1 + 0.9091} = \frac{1.8182}{1.9091} = 0.9524$$

$$W_{versicolor} = \frac{11}{30} = 0.3666$$

$$F1_{virginica} = \frac{2 * 0.8889 * 1}{0.8889 + 1} = \frac{1.7778}{1.8889} = 0.9412$$

$$W_{virginica} = \frac{8}{30} = 0.2667$$

# Metrics



Setosa: TP = 11 | FP = 0 | FN = 0

Versicolor: TP = 10 | FP = 0 | FN = 1

Virginica: TP = 8 | FP = 1 | FN = 0

$$F1\ score = \sum_{i=1}^n W_i * F1_i$$

$$F1\ score = (1 * 0.3666) + (0.9524 * 0.3666) + (0.9412 * 0.2667)$$

$$F1\ score = 0.9668$$

# Mestrado em Engenharia e Gestão Industrial

## Inteligência Artificial aplicada na Indústria

**Daniel Nogueira**



[dnogueira@ipca.pt](mailto:dnogueira@ipca.pt)



<https://www.linkedin.com/in/danielfnogueira/>

